

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №9

по дисциплине
«Математическая статистика»

Выполнил студент
группы 5030102/90101

Лаэтин Андрей Алексеевич

Проверил
Доцент, к.ф.-м.н.

Баженов Александр Николаевич

Санкт-Петербург
2022

СОДЕРЖАНИЕ

1	Постановка задачи	3
1.1	Исходные данные	3
1.2	Задача	4
2	Теория	4
2.1	Представление данных	4
2.2	Линейная регрессия	4
2.2.1	Описание модели	4
2.2.2	Метод наименьших модулей	5
2.3	Предварительная обработка данных	5
2.4	Коэффициент Жаккара	6
2.5	Процедура оптимизации	6
3	Реализация	6
4	Результаты	7
5	Приложение	10

1 Постановка задачи

Исследование из области солнечной энергетики [1]. На рис 1 показана схема установки для исследования фотоэлектрических характеристик.




Рис. 1: Схема установки для исследования фотоэлектрических характеристик.

Калибровка датчика ФП1 производится по эталону ФП2. Зависимость между квантовыми эффективностями датчиков предполагается одинаковой для каждой пары измерений

$$QE_{\text{ФП2}} = \frac{I_{\text{ФП2}}}{I_{\text{ФП1}}} * QE_{\text{ФП1}} \quad (1)$$

QE - квантовые эффективности эталонного и исследуемого датчиков, I - измеренные токи.

1.1 Исходные данные

Имеется 2 выборки данных с интервальной неопределенностью. Одна из них относится к эталонному датчику ФП2, другая - к исследуемому датчику ФП1.

1.2 Задача

Требуется определить коэффициент калибровки

$$R_{21} = \frac{I_2}{I_1} \quad (2)$$

при помощи линейной регрессии на множестве интервальных данных и коэффициента Жаккара.

2 Теория

2.1 Представление данных

В первую очередь представим данные таким образом, чтобы применить понятия статистики данных с интервальной неопределенностью.

Один из распространенных способов получения интервальных результатов в первичных измерениях - это "обинтерваливание" точечных значений, когда к точечному базовому значению x_0 , которое считывается по показаниям измерительного прибора, прибавляется *интервал погрешности* ε :

$$\mathbf{x} = \dot{x} + \varepsilon \quad (3)$$

Интервал погрешности зададим как

$$\varepsilon = [-\varepsilon; \varepsilon]$$

В конкретных измерениях примем $\varepsilon = 10^{-4}$ мВ.

Согласно терминологии интервального анализа, рассматриваемая выборка - это вектор интервалов, или интервальный вектор $x = (x_1, x_2, \dots, x_n)$.

2.2 Линейная регрессия

2.2.1 Описание модели

Линейная регрессия - регрессионная модель зависимости одной переменной от другой с линейной функцией зависимости:

$$y_i = X_i b_i + \varepsilon_i$$

где X - заданные значения, y - параметры отклика, ε - случайная ошибка модели. В случае, если у нас y_i зависит от одного параметра x_i , то модель выглядит следующим образом:

$$y_i = b_0 + b_1 * x_i + \varepsilon_i \quad (4)$$

В данной модели мы пренебрегаем погрешностью и считаем, что она получается при измерении y_i .

2.2.2 Метод наименьших модулей

Для наиболее точного приближения входных с фотоприемников данных y_i линейной регрессией $f(x_i)$ используется метод наименьших квадратов. Этот метод основывается на минимизации нормы разности последовательности:

$$\|f(x_i) - y_i\|_{l^1} \rightarrow \min \quad (5)$$

В данном случае ставится задача линейного программирования, решение которой дает нам коэффициенты b_0 и b_1 , а также вектор множителей коррекции данных w . По итогу получается следующая задача линейного программирования

$$\sum_{i=1}^n |w_i| \rightarrow \min \quad (6)$$

$$b_0 + b_1 * x_i - w_i * \varepsilon \leq y_i, i = 1..n \quad (7)$$

$$b_0 + b_1 * x_i + w_i * \varepsilon \leq y_i, i = 1..n \quad (8)$$

$$1 \leq w_i, i = 1..n \quad (9)$$

2.3 Предварительная обработка данных

Для оценки постоянной, как можно будет увидеть далее, необходима предварительная обработка данных. Займемся линейной моделью дрейфа.

$$Lin(n) = A + B * n, n = 1, 2, \dots, N \quad (10)$$

Поставив и решив задачу линейного программирования, найдем коэффициенты A , B и вектор w множителей коррекции данных для каждого из фотоприемников ФП1 и ФП2. В последствии множитель коррекции данных необходимо применить к погрешностям выборки, чтобы получить данные, которые согласовывались с линейной моделью дрейфа:

$$I^f(n) = \dot{x}(n) + \varepsilon * w(n), n = 1, 2, \dots, N \quad (11)$$

По итогу необходимо построить "спрямленные" данные выборки: получить их можно путем вычитания из исходных данных линейную компоненту:

$$I^c(n) = I^f(n) - B * n, n = 1, 2, \dots, N \quad (12)$$

2.4 Коэффициент Жаккара

Коэффициент Жаккара - мера сходства множеств. В интервальных данных рассматривается некоторая модификация этого коэффициента: в качестве меры множества (в данном случае интервала) рассматривается его длина, а в качестве пересечения и объединения - взятие минимума и максимума в интервальной арифметике соответственно. Можно заметить, что в силу возможности минимума по включению быть неправильным интервалом, коэффициент Жаккара может достигать значения только в интервале $[-1; 1]$.

$$JK(x) = \frac{width(\wedge x_i)}{width(\vee x_i)} \quad (13)$$

2.5 Процедура оптимизации

Чтоб найти оптимальный параметр калибровки R_{21} необходимо поставить и решить задачу максимизации коэффициента Жаккара, зависящего от параметра калибровки:

$$JK(I_1^c(n) * R \cup I_2^c(n)) \Rightarrow \max \quad (14)$$

где I_1^c и I_2^c - полученные спрямленные выборки, а R - параметр калибровки. Найденный таким образом R и будет искомым оптимальным R_{21} в силу наибольшего совпадения, оцененного коэффициентом Жаккара.

3 Реализация

Лабораторная работа была реализована при помощи языка программирования Python 3.9 с использованием библиотек NumPy, Matplotlib и SciPy.

4 Результаты




Рис. 2: Исходные данные из экспериментов

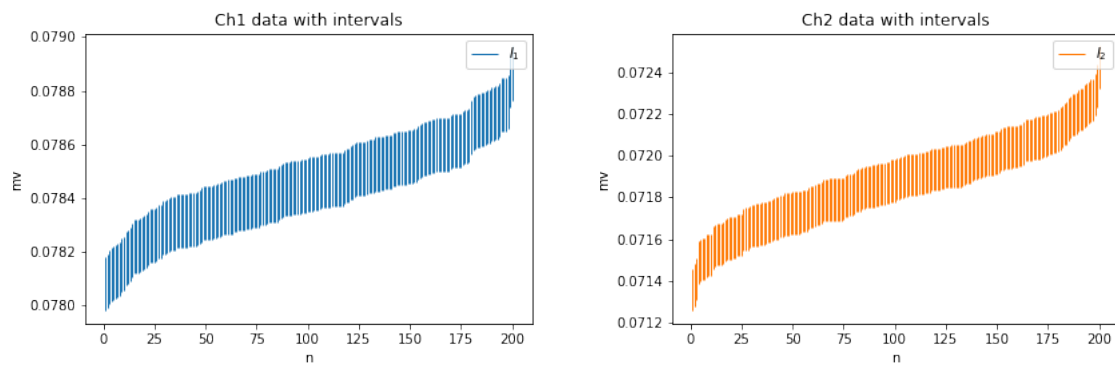


Рис. 3: Интервальное представление исходных данных




Рис. 4: Линейная модель дрейфа данных




Рис. 5: Гистограммы значений множителей коррекции w

Результаты линейного приближения токов.

- Для первого фотоприёмника:

$$A_1 = 0.0782143, B_1 = 2.33735 \cdot 10^{-6}$$

- Для второго фотоприёмника:

$$A_2 = 0.0715656, B_2 = 3.08633 \cdot 10^{-6}$$




Рис. 6: Скорректированные модели данных




Рис. 7: Гистограммы скорректированных данных

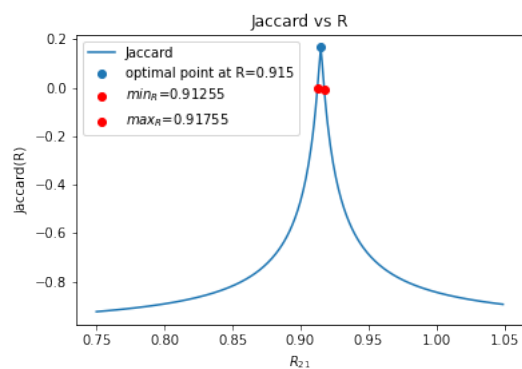


Рис. 8: Значение коэффициента Жаккара от калибровочного множителя от R21

Результаты исследования:

$$R_{opt} = 0.915, jaccard(R) = 0.165814$$




Рис. 9: Гистограмма объединённых данных при оптимальном значении R21

5 Приложение

Код программы GitHub URL:

<https://github.com/A21163/math-prob-stat>